



UNIVERSIDAD DE BURGOS
ESCUELA POLITÉCNICA SUPERIOR
Grado en Ingeniería en Informática



TFG del Grado en Ingeniería Informática

**Ensembles de clasificadores
multi-label en Scikit-Learn**



Presentado por Eduardo Tubilleja Calvo
en Universidad de Burgos — 17 de enero de 2018

Tutor: Dr. Álgvar Arnaiz González
y Dr. Juan José Rodríguez Díez



UNIVERSIDAD DE BURGOS
ESCUELA POLITÉCNICA SUPERIOR
Grado en Ingeniería en Informática



D. Álgvar Arnaiz González y D. Juan José Rodríguez Díez, profesores del departamento de nombre departamento de Ingeniería Civil, área de Lenguajes y Sistemas Informáticos.

Exponen:

Que el alumno D. Eduardo Tubilleja Calvo, con DNI 71298897R, ha realizado el Trabajo final de Grado en Ingeniería Informática titulado «Ensembles de clasificadores multi-label en Scikit-Learn».

Y que dicho trabajo ha sido realizado por el alumno bajo la dirección del que suscribe, en virtud de lo cual se autoriza su presentación y defensa.

En Burgos, 17 de enero de 2018

Vº. Bº. del Tutor:

Vº. Bº. del Tutor:

D. Álgvar Arnaiz González

D. Juan José Rodríguez Díez

Resumen

En este primer apartado se hace una **breve** presentación del tema que se aborda en el proyecto.

Descriptores

Palabras separadas por comas que identifiquen el contenido del proyecto Ej: servidor web, buscador de vuelos, android . . .

Abstract

A **brief** presentation of the topic addressed in the project.

Keywords

keywords separated by commas.

Índice general

Índice general	III
Índice de figuras	V
Índice de tablas	VI
Introducción	1
Objetivos del proyecto	2
2.1. Objetivos	2
Conceptos teóricos	4
3.1. Minería de Datos	4
3.2. Multi-Label	5
3.3. Ensemble	6
3.4. Disturbing Neighbors	6
3.5. Referencias	9
3.6. Imágenes	9
3.7. Listas de items	10
3.8. Tablas	11
Técnicas y herramientas	12
4.1. GitHub	12
4.2. Spyder	13
4.3. L ^A T _E X	13
4.4. Jupyter Notebook	13
4.5. Scikit-learn	13
Aspectos relevantes del desarrollo del proyecto	15

<i>ÍNDICE GENERAL</i>	IV
Trabajos relacionados	16
Conclusiones y Líneas de trabajo futuras	17
Bibliografía	18

Índice de figuras

3.1. Autómata para una expresión vacía	10
--	----

Índice de tablas

3.1. Herramientas y tecnologías utilizadas en cada parte del proyecto	11
---	----

Introducción

La minería de datos es un campo de la estadística y las ciencias de la computación, que consisten en el análisis de grandes cantidades de datos para descubrir patrones. Utiliza el método del aprendizaje automático, éste pertenece a un subcampo de las ciencias de computación y de la rama de inteligencia artificial, el objetivo de éste es desarrollar unas técnicas que permitan que las máquinas aprendan. Dentro de este aprendizaje se encuentra el aprendizaje supervisado, en él normalmente los conjuntos de datos suelen tener solo una variable a predecir, conocido como single-label, pero aparecido el multi-label, este hace referencia a los conjuntos de datos en lo que cada elemento de la base de datos puede pertenecer a más de una clase, como por ejemplo en el etiquetado de imágenes: en el que una imagen puede tener a la vez las etiquetas «árbol», «montaña» y «mar». En este proyecto vamos a tratar sobre implementar diversos algoritmos de clasificadores (ensembles), para multi-label sobre la librería Scikit Learn de Python. Se ha seguido la guía de estilo de Python (PeP) y Sklearn. Para que se entienda mejor y sea más gráfico, se han dibujado árboles y gráficas, mostrando los resultados al ejecutar dichos algoritmos sobre un conjunto de datos. Los algoritmos en los que nos vamos a centrar son Disturbing Neighbors, Random Oracles y Rotation Forest.

La precisión global de los ensembles necesita que los clasificadores base predigan correctamente la clase de las mismas instancias. Tienen que ser diferentes para complementarse entre ellos. ¿Cómo puede un ensemble de clasificadores base que han sido generados por el mismo algoritmo tener distintas salidas, si las entradas son las mismas? Una de las estrategias que podemos usar para ello son los ensembles heterogéneos, es decir, mismo conjunto de datos distintos clasificadores.

Objetivos del proyecto

En este apartado se explica cuales son los objetivos que se persiguen con la realización del proyecto, y que han motivado a su realización.

2.1. Objetivos

A continuación se muestra el esquema con todos los puntos a tratar en este proyecto.

- Implementar el algoritmo Disturbing Neighbors en Scikit-learn:
 - Que sirva para datos Single-Label o Multi-Label
 - Crear el método `fit` para entrenar un conjunto de datos.
 - Crear el método `predict` para predecir según el entrenamiento de unos datos.
 - Crear el método `predict_proba` para predecir probabilidades según el entrenamiento de unos datos.
 - Probar que la clase funciona correctamente.
- Implementar el algoritmo Random Oracles en Scikit-learn:
 - Que sirva para datos Single-Label o Multi-Label
 - Crear el método `fit` para entrenar un conjunto de datos.
 - Crear el método `predict` para predecir según el entrenamiento de unos datos.
 - Crear el método `predict_proba` para predecir probabilidades según el entrenamiento de unos datos.
 - Probar que la clase funciona correctamente.
- Implementar el algoritmo Rotation Forest en Scikit-learn:

- Que sirva para datos Single-Label o Multi-Label
 - Crear el método `fit` para entrenar un conjunto de datos.
 - Crear el método `predict` para predecir según el entrenamiento de unos datos.
 - Crear el método `predict_proba` para predecir probabilidades según el entrenamiento de unos datos.
 - Probar que la clase funciona correctamente.
- Crear un notebook para mostrar:
 - Los resultados en notebooks de jupyter de los distintos algoritmos.
 - Usar una semilla para que los datos no cambien y poder compararlos.
 - Mostrar en un árbol la clasificación del conjunto.
 - Mostrar gráficas para comparar como se dividen los datos y ver cual de los algoritmos es mejor en cada caso.
 - Mostrar resultados al usar validación cruzada.

Conceptos teóricos

Este apartado va tratar sobre la explicación de los conceptos necesarios para poder entender el proyecto.

3.1. Minería de Datos

Es conocida la frase «los datos en bruto raramente son beneficiosos directamente». Aunque puede tener valor, ya que podemos extraer información útil para la toma de decisiones o exploración, y también para la comprensión del fenómeno dominante en el conjunto de datos. [?].

La finalidad de esto es descubrir unos patrones, una similitud o una propensión que expliquen el comportamiento de los datos. Para hacer esto utiliza los métodos de la inteligencia artificial, estadística y redes neuronales. El objetivo del proceso de minería de datos consiste en extraer información de un conjunto de datos, luego se interpreta esta información para un uso posterior. [13].

La minería de datos es conocida como un sinónimo de KDD (Descubrimiento del conocimiento de los datos): Es el proceso del descubrimiento del conocimiento de los datos tiene una secuencia de pasos [2]:

1. Limpieza de datos. Eliminación del ruido y la inconsistencia de los datos.
2. Integración de los datos. Múltiples fuentes de datos son combinadas.
3. Selección de datos. Los datos relevantes para la tarea de análisis se recuperan de la base de datos.
4. Transformación de datos. Los datos son transformados y se consolidan como apropiados para la minería mediante la realización de operaciones simétricas o de agregación.

5. Minería de datos. Es un proceso esencial donde los métodos de inteligencia son aplicados a la extracción de patrones.
6. Evaluación de patrones. Identificar los patrones que de verdad son interesantes, que representan el conocimiento basado en medidas de interés.
7. Presentación del conocimiento. La visualización y el conocimiento representan técnicas que son utilizadas para presentar la minería del conocimiento a los usuarios.

Aunque el proceso de la minería de datos consta de más etapas nosotros nos centraremos en 4 etapas [11]:

Determinación de los objetivos

Se tratan los objetivos que quiere conseguir el cliente bajo un asesor especialista en minería de datos.

Preprocesamiento de los datos

Es la etapa que más tiempo se tarda en realizar el proceso. Se seleccionan, limpian, enriquecen, reducen y transforman las bases de datos.

Determinación del modelo

Se lleva a cabo un estudio estadístico de los datos, más tarde se hace una visualización gráfica para una primera aproximación. Según los objetivos que se habían propuesto se pueden usar diferentes algoritmos de la Inteligencia Artificial.

Análisis de los resultados

Se comprueban si los datos obtenidos tienen coherencia, después se comparan con los obtenidos en los estudios estadísticos y la visualización gráfica. El cliente es el que ve si los datos le aportan nuevo conocimiento que le permita considerar sus decisiones.

3.2. Multi-Label

La clasificación multi-label es una técnica de minería de datos, nos permite que de un conjunto de instancias de entrenamiento, podamos determinar a partir de unos atributos esenciales de dichas instancias para crear unas reglas que posteriormente se usarán para clasificar nuevas instancias [8].

3.3. Ensemble

Los métodos de ensembles combinan las predicciones de unos estimadores base, que están contruidos mediante un algoritmo de aprendizaje para mejorar la solidez de un solo estimador [10]. Se distinguen dos clases de métodos de ensembles:

- En los métodos de promedio, se construyen varios estimadores de forma independiente y luego se calcula su promedio para las predicciones. En general el estimador combinado es mejor que un estimador de base única.
- En los métodos de impulso, se construyen los estimadores secuencialmente y se trata de reducir el sesgo del estimador combinado. El objetivo es combinar varios modelos débiles para conseguir un conjunto fuerte.

3.4. Disturbing Neighbors

Está organizado de la siguiente manera. La subsección 1 se explica la introducción. La subsección 2 describe el método del vecino moleston. La subsección 3 analiza experimentalmente nuestro método aplicado a los conjuntos representativos del estado del arte de SVM. La subsección 4 concluye.

Introducción

Un ensemble es un esquema de combinación de predicciones individuales llamados clasificadores base. El éxito de un ensemble requiere tanto exactitud como diversidad de sus clasificadores base. La diversidad representa como diferente son las predicciones de los clasificadores base. Si los clasificadores base siempre están de acuerdo podría no haber diferencia entre usar sólo un clasificador base o varios combinado por un método de ensemble. Entonces el poder de usar un conjunto de clasificadores base consiste en la posibilidad que algunos de ellos pueden corregir una predicción incorrecta de otros.

Es normal obtener estos clasificadores base en un ensemble usando el mismo algoritmo, así que en esta situación el proceso de entrenamiento realizado por el ensemble es la principal fuente de diversidad. La diversidad de Bagging proviene de elegir al azar diferentes instancias para entrenar a cada clasificador de base. El método Random Subspaces elige diferentes subconjuntos de atributos para entrenar a cada clasificador base. Boosting entrena de forma iterativa el conjunto de clasificadores base, modificando los pesos de las instancias para entrenar al clasificador actual. Estos nuevos pesos se calculan a partir del error de entrenamiento en el clasificador base anterior, por lo que cada nuevo clasificador de base llega más especializado en instancias que han sido mal clasificados antes. A veces los clasificadores base son muy estables y

el algoritmo de entrenamiento del ensemble no es suficiente para proporcionar el nivel deseado de diversidad.

SVM (Support Vector Machine) calcula un hiperplano óptimo que separa el espacio de entrada en dos regiones correspondientes a las clases de un conjunto de datos de dos clases. Si el conjunto de datos no es separable linealmente, el hiperplano puede construirse sin tal problema en el espacio de características dado por una función kernel. Cuando no se usa kernel, se dice que el kernel es lineal. El kernel lineal es más apropiado para datasets linealmente separables. Sin embargo, también es una opción interesante para otros conjuntos de datos, ya que es el más rápido y existen implementaciones optimizadas. Además, si no es posible la separación completa, pueden introducirse variables de holgura para permitir errores de entrenamiento. Por lo tanto, el kernel lineal es una opción muy competitiva cuando se deben construir numerosos SVM, como ocurre con los ensambles. Por esa razón, este documento está enfocado solo en SVM lineal. Sin embargo, algunas de sus conclusiones podrían ser válidas para otros kernels. Se sabe que SVM es un clasificador muy estable, por lo que se espera que los conjuntos de SVM se beneficien de estrategias que contribuyan a aumentar su diversidad.

Los Disturbing Neighbors (DN) o vecinos molestos se han utilizado con éxito para mejorar la diversidad en los bosques. DN usa un clasificador de 1-Nearest Neighbour (1-NN) para construir un conjunto de características adicionales que se agregan al conjunto de datos de entrenamiento de cada clasificador base. Este clasificador 1-NN es diferente para cada clasificador base. Las características compiladas son la predicción 1-NN más un conjunto booleano de características que indican cuál es el vecino más cercano. El conjunto de datos de entrenamiento original se transforma en un conjunto de datos aumentados, que es diferente para cada clasificador base, independientemente del esquema de conjunto en el que se va a utilizar.

A diferencia de SVM, los árboles de decisión son muy sensibles a pequeños cambios en el conjunto de datos de capacitación. La motivación de este documento es probar DN dentro de conjuntos SVM para ver si la precisión y la diversidad aumentan, al igual que en los bosques, a pesar de la estabilidad SVM.

Método

El método DN trabaja en cada clasificador base de la siguiente manera:

1. m instancias son seleccionadas aleatoriamente de el conjunto de datos de entrenamiento para construir un clasificador 1-NN. El valor m usa valores muy pequeños.

2. Dimensiones usadas para calcular distancia euclídea en el clasificador 1-NN son también seleccionadas aleatoriamente. Al menos el 50 % de los atributos son seleccionados.
3. Luego $m+1$ nuevas características son añadidas al conjunto de entrenamiento. Una de las características adicionales es la clase predecida por el clasificador 1-NN para cada instancia x , y la otra m son características booleanas, todos los conjuntos falsos excepto uno corresponden al vecino más cercano para esa instancia.
4. El clasificador base está entrenado usando las características originales mas las nuevas características de $m+1$.

Por lo tanto, el proceso normal de entrenamiento de los clasificadores básicos se altera añadiendo estas nuevas características del clasificador 1-NN. Es por eso que el método se llama vecinos molestones. La aleatoriedad aumenta la diversidad y se debe a:

- Los vecinos utilizados en cada clasificador 1-NN se seleccionan aleatoriamente. Por lo tanto, sus predicciones y las características booleanas son diferentes para cada clasificador base.
- Las dimensiones utilizadas para calcular las distancias euclidianas también se eligen de forma aleatoria, así que si dos clasificadores básicos tienen al menos los mismos m vecinos, las predicciones 1-NN y las características booleanas podrían ser diferentes.

El valor m es muy pequeño ya que el objetivo no es crear un clasificador 1-NN muy preciso, sino uno diferente cada vez. Las características m booleanas pueden ser tenidas en cuenta por el SVM resultante, por lo que se espera que cada SVM sea diferente. Como las predicciones de clase 1-NN son nominales, deben transformarse en binarias características para ser calculadas por el algoritmo de entrenamiento SVM. Estas características binarias también dividen el espacio de entrada en regiones cuyo número es igual o menor que el número de clases. En realidad, cada región resultante de esta nueva división es la unión de las regiones de Voronoi correspondientes a los vecinos que comparten la misma clase. Así que otra vez, tenemos un conjunto de atributos booleanos que pueden cambiar los coeficientes de SVM. Por lo tanto, las dimensiones adjuntas por DN pueden ser utilizadas por cada SVM en el ensemble. La aleatoriedad introducida hace que estas dimensiones sean diferentes para cada SVM, por lo que se obtienen diversos hiperplanos cada vez.

Resultados

Conclusión

Disturbing Neighbors es un método para alterar el proceso de entrenamiento normal de los clasificadores base en un ensemble, mejorando su diversidad y mejorando la precisión general del ensemble. Disturbing Neighbors crea nuevas características utilizando un clasificador 1-NN. Estas características son la salida 1-NN más un conjunto de atributos booleanos que indican cuál es el vecino más cercano. El clasificador 1-NN se crea utilizando un pequeño subconjunto de instancias de entrenamiento seleccionadas al azar del conjunto de datos original. Las dimensiones utilizadas para calcular la distancia euclidiana también se seleccionan de forma aleatoria. Estas dos fuentes de aleatoriedad son las razones por las que las características creadas son diferentes cada vez, por lo que cuando estas nuevas características se usan para entrenar clasificadores base, la diversidad aumenta. La estadística de Kappa y los diagramas de movimiento de Kappa muestran que DN proporciona una diversidad adicional a los alumnos de base de SVM. La validación experimental también muestra que DN-SVM no mejora significativamente la precisión de SVM, mientras que los conjuntos de SVM que usan DN son significativamente mejores que las versiones sin DN. De modo que esta mejora solo puede venir del incremento en diversidad obtenido al aplicar DN.

3.5. Referencias

Las referencias se incluyen en el texto usando cite [12]. Para citar webs, artículos o libros [4].

3.6. Imágenes

Se pueden incluir imágenes con los comandos standard de L^AT_EX, pero esta plantilla dispone de comandos propios como por ejemplo el siguiente:



Figura 3.1: Autómata para una expresión vacía

3.7. Listas de ítems

Existen tres posibilidades:

- primer ítem.
- segundo ítem.

1. primer ítem.
2. segundo ítem.

Herramientas	App	AngularJS	API REST	BD	Memoria
HTML5		X			
CSS3		X			
BOOTSTRAP		X			
JavaScript		X			
AngularJS		X			
Bower		X			
PHP			X		
Karma + Jasmine		X			
Slim framework			X		
Idiorm			X		
Composer			X		
JSON		X	X		
PhpStorm		X	X		
MySQL				X	
PhpMyAdmin				X	
Git + BitBucket		X	X	X	X
MikTeX					X
TeXMaker					X
Astah					X
Balsamiq Mockups		X			
VersionOne		X	X	X	X

Tabla 3.1: Herramientas y tecnologías utilizadas en cada parte del proyecto

Primer ítem más información sobre el primer ítem.

Segundo ítem más información sobre el segundo ítem.

■

3.8. Tablas

Igualmente se pueden usar los comandos específicos de \LaTeX o bien usar alguno de los comandos de la plantilla.

Técnicas y herramientas

En este apartado de la memoria se presentan las técnicas metodológicas y las herramientas de desarrollo que se han utilizado para llevar a cabo el proyecto.

4.1. GitHub

Es una plataforma para alojar proyectos y utiliza git como sistema de control de versiones. Se organiza por tareas (milestones e issues). Utiliza el framework Ruby on Rails [6].

Podemos acceder a él a través del siguiente enlace: <https://github.com/>

Ventajas:

- Es uno de los repositorios mas usados, por lo que es fácil encontrar información en Internet para resolver cualquier duda.
- El código es público por lo que cualquiera puede proponer cambios en el mismo, seguirte y ver el proyecto.
- Las distintas versiones del código están alojadas en la nube por lo que si perdemos el contenido de nuestro ordenador, podremos recuperarlo.

Desventajas:

- También puedes tener proyectos privados pero para ello tienes que utilizar una cuenta de pago, aunque los estudiantes e investigadores pueden obtener esto gratuitamente.

4.2. Spyder

Es un entorno de desarrollo interactivo para el lenguaje de Python, es de código abierto. Tiene funciones avanzadas de edición, pruebas interactivas, depuración e introspección. También es un entorno informático numérico y tiene diversas bibliotecas que podemos utilizar, como pueden ser numpy [9].

Podemos acceder a él a través del siguiente enlace: <http://pythonhosted.org/spyder/>

4.3. L^AT_EX

Se usa para la creación de documentos que necesiten una alta calidad tipográfica, como puede ser en artículos o libros científicos [5].

Ventajas:

- Es software libre, por lo que no requiere ningún coste.
- No te tienes preocupar por el diseño, ya que la herramienta se encarga de ello.

Desventajas:

- Si eres principiante necesitas un tiempo de aprendizaje para saber como funciona.

Podemos acceder a él a través del siguiente enlace: <https://www.latex-project.org/>

4.4. Jupyter Notebook

Es una aplicación web de código abierto, con él podemos crear y compartir documentos, que nos permiten visualizar los resultados al ejecutar nuestro código, ya sean imágenes, árboles...que otros entornos de desarrollo (como Spyder mencionado anteriormente) no nos permiten esto. Soporta más lenguajes, pero nosotros lo usaremos para el lenguaje de Python [3].

Podemos acceder a él a través del siguiente enlace: <http://jupyter.org/>

4.5. Scikit-learn

Es una librería de aprendizaje de software libre del lenguaje de programación de Python. Es una herramienta de las más utilizadas para la minería

de datos y el análisis de datos [1]. Esta basada en el aprendizaje automático, para ello se consideran un conjunto de n muestras y se intenta predecir las propiedades de los datos desconocidos. Podemos separar los problemas de aprendizaje en dos [7]:

- Aprendizaje supervisado: En el que los datos vienen con atributos adicionales que queremos predecir. Dos de las tareas mas comunes son la clasificación y la regresión. En las de clasificación el programa debe aprender a predecir en que categoría o clase irán los nuevos datos según las nuevas observaciones, como sería predecir si el precio de una acción bajara o subirá. En lo de regresión el programa debe predecir el valor de una variable de respuesta continua, como sería predecir las ventas de un nuevo producto.
- Aprendizaje no supervisado: Consiste en agrupar observaciones relaciones, dentro de los datos del entrenamiento. Clustering es la que más se utiliza para explorar un conjunto de datos.

Aspectos relevantes del desarrollo del proyecto

Este apartado pretende recoger los aspectos más interesantes del desarrollo del proyecto, comentados por los autores del mismo. Debe incluir desde la exposición del ciclo de vida utilizado, hasta los detalles de mayor relevancia de las fases de análisis, diseño e implementación. Se busca que no sea una mera operación de copiar y pegar diagramas y extractos del código fuente, sino que realmente se justifiquen los caminos de solución que se han tomado, especialmente aquellos que no sean triviales. Puede ser el lugar más adecuado para documentar los aspectos más interesantes del diseño y de la implementación, con un mayor hincapié en aspectos tales como el tipo de arquitectura elegido, los índices de las tablas de la base de datos, normalización y desnormalización, distribución en ficheros³, reglas de negocio dentro de las bases de datos (EDVHV GH GDWRV DFWLYDV), aspectos de desarrollo relacionados con el WWW... Este apartado, debe convertirse en el resumen de la experiencia práctica del proyecto, y por sí mismo justifica que la memoria se convierta en un documento útil, fuente de referencia para los autores, los tutores y futuros alumnos.

Trabajos relacionados

Este apartado sería parecido a un estado del arte de una tesis o tesina. En un trabajo final grado no parece obligada su presencia, aunque se puede dejar a juicio del tutor el incluir un pequeño resumen comentado de los trabajos y proyectos ya realizados en el campo del proyecto en curso.

Conclusiones y Líneas de trabajo futuras

Todo proyecto debe incluir las conclusiones que se derivan de su desarrollo. Éstas pueden ser de diferente índole, dependiendo de la tipología del proyecto, pero normalmente van a estar presentes un conjunto de conclusiones relacionadas con los resultados del proyecto y un conjunto de conclusiones técnicas. Además, resulta muy útil realizar un informe crítico indicando cómo se puede mejorar el proyecto, o cómo se puede continuar trabajando en la línea del proyecto realizado.

Bibliografía

- [1] Wikipedia contributors. Scikit-learn — wikipedia, the free encyclopedia, 2017. [Online; accessed 3-January-2018].
- [2] Jiawei Han, Jian Pei, and Micheline Kamber. *Data mining: concepts and techniques*. Elsevier, 2011.
- [3] jupyter. Jupyter-notebook, 2017. [Online].
- [4] John R. Koza. *Genetic Programming: On the Programming of Computers by Means of Natural Selection*. MIT Press, 1992.
- [5] latex project. Latex, 2017. [Online].
- [6] Carlos Paramio. Github, 2011. [Online].
- [7] F. Pedregosa, G. Varoquaux, A. Gramfort, V. Michel, B. Thirion, O. Grisel, M. Blondel, P. Prettenhofer, R. Weiss, V. Dubourg, J. Vanderplas, A. Passos, D. Cournapeau, M. Brucher, M. Perrot, and E. Duchesnay. Scikit-learn: Machine learning in Python. *Journal of Machine Learning Research*, 12:2825–2830, 2011.
- [8] Julio Antonio Hernández Pérez, Raudel Hernández León, and Tercer C Autor. Clasificación multi-etiquetas basada en reglas de asociación de clases.
- [9] pythonhosted. Spyder, 2017. [Online].
- [10] scikit learn. Ensemble, 2017. [Online].
- [11] sinnexus. Minería de datos, 2016. [Online].
- [12] Wikipedia. Latex — wikipedia, La enciclopedia libre, 2015. [Internet; descargado 30-septiembre-2015].

- [13] Wikipedia. Minería de datos — wikipedia, la enciclopedia libre, 2017.
[Internet; descargado 3-enero-2018].